

◎网络、通信、安全◎

个性化推荐系统综述

王国霞, 刘贺平

WANG Guoxia, LIU Heping

北京科技大学 自动化学院, 北京 100083

School of Automation, University of Science & Technology Beijing, Beijing 100083, China

WANG Guoxia, LIU Heping. Survey of personalized recommendation system. Computer Engineering and Applications, 2012, 48(7): 66-76.

Abstract: Information overload is one of the most critical problems, and personalized recommendation system is a powerful tool to solve this problem. In this article, the definition of recommendation system is introduced, this article also expounds some key technologies including user modeling, recommendation item modeling and recommendation algorithm. The recommendation frame and evaluation methods are also exhibited. This article tries to give the difficulties and future directions of recommendation system.

Key words: recommendation system; information overload; recommendation algorithm; personalization

摘 要:信息超载是目前网络用户面临的一个严重问题,个性化推荐系统是解决该问题的一个有力工具,并受到了众多的关注和研究。给出推荐系统的定义,同时阐述了推荐系统的几项关键技术,包括用户建模、推荐对象的建模和推荐算法。后来总结了推荐系统的体系结构和性能评价指标,并尝试给出了推荐系统未来研究的重点、难点和热点问题。

关键词:推荐系统;信息超载;推荐算法;个性化

DOI:10.3778/j.issn.1002-8331.2012.07.018 文章编号:1002-8331(2012)07-0066-11 文献标识码:A 中图分类号:TP18

互联网的出现和普及给用户带来了大量的信息,满足了用户在信息时代对信息的需求,但随着网络的迅速发展而带来的网上信息量的大幅增长,使得用户在面对大量信息时无法从中获得对自己真正有用的那部分信息,对信息的使用效率反而降低了,这就是所谓的信息超载(information overload)问题。

目前,针对信息超载问题的解决办法之一是以搜索引擎为代表信息检索系统,比如Google、Baidu等,它们在帮助用户获取网络信息方面发挥着极其重要的作用。但使用搜索引擎的用户在使用同一个关键字搜索信息时,得到的结果是相同的^[1]。另一方面来看,信息及其传播是多样化的,而用户对信息的需求是多元化和个性化的,那么通过以搜索引擎为代表的信息检索系统获得的结果不能满足用户的个性化需求,仍然无法很好地解决信息超载问题。

解决信息超载问题另外一个非常有潜力的办法是个性化推荐系统,它是根据用户的信息需求、兴趣等,将用户感兴趣的信息、产品等推荐给用户的个性化信息推荐系统。和搜索引擎相比推荐系统通过研究用户的兴趣偏好,进行个性化计算,由系统发现用户的兴趣点,从而引导用户发现自己的信息需求。一个好的推荐系统不仅能为用户提供个性化的服务,还能和用户之间建立密切关系,让用户对推荐产生依赖。

个性化推荐系统现已广泛应用于很多领域,其中最典型并具有良好的发展和应用前景的领域就是电子商务领域。同时学术界对推荐系统的研究热度一直很高,逐步形成了一门独立的学科,本文就推荐系统的几项关键技术研究给予了关注。

1 推荐系统的概念和定义

推荐系统的定义有不少,但被广泛接受的推荐系统的概念和定义是Resnick和Varian在1997年^[2]给出的:“它是利用电子商务网站向客户提供商品信息和建议,帮助用户决定应该购买什么产品,模拟销售人员帮助客户完成购买过程”。

推荐系统有3个重要的模块:用户建模模块、推荐对象建模模块、推荐算法模块。通用的推荐系统模型流程如图1所示^[3]。推荐系统把用户模型中兴趣需求信息和推荐对象模型中的特征信息匹配,同时使用相应的推荐算法进行计算筛选,找到用户可能感兴趣的推荐对象,然后推荐给用户。




图1 推荐系统通用模型

推荐系统的形式化定义如下^[4-5]:设 C 是所有用户的集合, S 是所有可以推荐给用户的对象的集合。实际上, C 和 S 集合的规模通常很大,如上百万的顾客以及上亿种歌曲等。设效用函数 $u()$ 可以计算对象 s 对用户 c 的推荐度(如提供商的可靠性(vendor reliability)和产品的可得性(product availability)等),即 $u:C \times S \rightarrow R$, R 是一定范围内的全序的非负实数,推荐要研究的问题就是找到推荐度 R 最大的那些对象 S^* ,如式(1):

$$\forall c \in C, S^* = \arg \max_{s \in S} u(c, s) \quad (1)$$

作者简介:王国霞(1975—),女,博士研究生,讲师,主要研究方向为个性化信息获取;刘贺平(1951—),男,教授,博士生导师。

E-mail: my_zhg0127@sina.com

收稿日期:2011-09-08;修回日期:2011-11-01

从上述模型和定义可以看出,推荐系统关键技术有三个方面,分别是用户建模、推荐对象的建模和推荐算法。下文分别对这几项技术给以说明。

2 用户建模模块

一个好的推荐系统要给用户提供一个个性化的、高效的、准确的推荐,那么推荐系统应能够获取反映用户多方面的、动态变化的兴趣偏好,推荐系统有必要为用户建立一个用户模型,该模型能获取、表示、存储和修改用户兴趣偏好,能进行推理,对用户进行分类和识别,帮助系统更好地理解用户特征和类别,理解用户的需求和任务,从而更好地实现用户所需要的功能。推荐系统根据用户的模型进行推荐,所以用户描述文件对推荐系统的质量有至关重要的影响。建立用户模型之前,需要考虑下面几个问题^[6-7]:

- (1)模型的输入数据有哪些,如何获取模型的输入数据。
- (2)如何考虑用户的兴趣及需求的变化。
- (3)建模的对象是谁。
- (4)清楚了上述内容后,怎么建模呢。
- (5)模型的输出是什么。

用户建模的大致过程如图2所示。




图2 用户建模的过程

图2中获取用户信息就是解决模型输入数据的问题,模型的输入数据主要有以下几种:

(1)用户属性:这是用户最基本的信息,包括社会属性和自然属性,比如用户的姓名、年龄、职业、收入、学历等。文献[8-9]用用户注册时的自然属性和社会属性进行初始建模。

(2)用户手工输入的信息:这部分是用户主动提供给系统的信息,包括用户在搜索引擎中输入的关键词,用户输入的兴趣的主题、频道。还有一类重要的信息就是用户反馈的信息,包括用户自己对推荐对象的喜好程度^[10];用户标注的浏览页面的感兴趣、不感兴趣或感兴趣的程度等。

(3)用户的浏览行为和浏览内容:用户浏览的行为和内容体现了用户的兴趣和需求,它们包括浏览次数、频率、停留时间等,浏览页面时的操作(收藏、保存、复制等)、浏览时用户表情的变化等。服务器端保存的日志也能较好地记录用户的浏览行为和-content。

(4)推荐对象的属性特征:不同的推荐对象,用户建模的输入数据也不同。网页等推荐对象通常考虑对象的内容和用户之间的相似性,而产品等推荐对象通常考虑用户对产品的评价。为提高推荐质量,推荐对象的相关的属性也要考虑进去,比如除网页内容以外,还要考虑网页的发布人、时间等。产品类的对象还要考虑产品的品牌、价格、出售时间等。文献[11-12]扩展了二维的评价矩阵,综合考虑了影响用户兴趣的各种因素。文献[13-14]考虑了Web服务的Qos来对用户的兴趣建模。

获取模型输入数据的方式有显式获取、隐式获取和启发式获取三种方式。显式的获取方式用户主动告之。例如

MyYahoo和WebWatcher^[15]都要用户自己给出感兴趣的栏目和关键。另外一类显式的方式要求用户提供与其兴趣相关的示例及类别属性来建立用户模型,LIRA、Syskill&Webert、WebMate等是该方法的代表。

显式获取兴趣偏好的方法是简单而直接的做法,能相对准确地反映用户的需求,同时所得的信息比较具体、全面、客观,结果往往比较可靠。缺点就是很难收到实效,主要原因就是很少用户愿意花时间或不愿向系统表达自己的喜好。而且这一方法灵活性差,存在答案异质性,用户兴趣主题改变时要手动更改系统中用户兴趣等诸多问题,使得该方法的实时性、可操作性很难得到保证。同时该方法对用户不是很友好,具有很大的侵袭性^[3]。解决侵袭性问题是推荐系统未来的一个研究方向,来研究用户能够接受的评价方式是什么,比如能够有耐心进行几次评分。文献[16]利用固定负担模型来计量用户评价的负担,将侵袭性问题转化为最优化问题来研究。

隐式获取法是指系统通过跟踪用户行为,通过推理获取用户的兴趣偏好,因为用户的很多动作都能暗示用户的喜好,比如查询、浏览页面和文章、标记书签、反馈信息、点击鼠标、拖动滚动条,Web日志挖掘^[17-19]等。典型的系统有ELFI^[20]、Letizia^[21]等。隐式的跟踪可以减少用户很多不必要的负担,不会打扰用户的正常生活。这种方法的缺点就是跟踪的结果未必能正确反映用户的兴趣偏好,如在文献[22]中认为利用日志跟踪用户兴趣偏好存在兴趣偏好走样的问题。同时系统若过度跟踪用户的历史记录,有时会引起用户反感,而放弃对当前推荐系统的使用。

上述获取兴趣偏好的方法有时受用户知识背景、资源和经验等方面因素的限制,用户有时意识不到自己的兴趣主题,因此,为用户提供启发式信息,如专家意见、领域术语抽取,可以实现领域知识的复用,为用户间的协同提供支持,提高用户兴趣获取质量。

用户的兴趣和需求会随着时间的和情景发生变化,用户建模时要考虑到用户长期兴趣偏好和短期兴趣偏好,还要考虑兴趣的变化,目前很多研究关注了用户的长期兴趣,建立了静态模型,用户兴趣更新的动态模型也受到了很多关注,短期兴趣的关注还比较少。结合长期和短期兴趣的建模将是未来的一个研究方向,文献[23]对此进行了研究。而且采用时间窗方法^[24]和遗忘机制^[25]来反映用户兴趣的变化。目前的更新机制无法及时跟踪用户兴趣的变化,just-in-time型有更强学习效率和动态变化适应能力的建模也是未来的重要研究方向。

建模的对象有单用户建模和群组建模之分,单用户建模针对单个用户进行建模,比如基于内容的推荐,群组建模是针对群体用户进行建模,比如协同推荐。

用户建模的输出即用户模型的表示方法有很多种,使用用户感兴趣的信息主题表示用户模型的主题表示法,比如Google、Microsoft AOL。多用于协同推荐的用户-项目评价矩阵表示法,并且文献[11-12]提出了多维空间来扩展用户-项目评价矩阵。利用用户检索过的案例或者与案例相关的一组属性值来表示用户兴趣偏好的案例表示法,如CA SPER系统^[26]、WebWatcher、TAGUS系统、BGP-MS系统、LIRA、Syskill&Webert等。基于本体论的表示法用一个本体来表示用户感兴趣的领域,例如Quickstep系统和aceMedia系统。文献[21,23]中提出了容易理解那个方便修改和补充的细粒度模型表示法。

用户模型的建模方法主要有遗传算法、基于机器学习的方法,例如TF-IDF、自动聚类、贝叶斯分类器、决策树归纳和神经网络方法等。

遗传算法采用遗传结合、遗传交叉变异以及自然选择等操作实现建模,通过遗传进化满足用户兴趣变化时完成模型的更新^[14,27]。

TF-IDF将用户感兴趣的文档表示成关键词向量,并计算出每个关键词权重来建立用户模型;使用贝叶斯分类器的系统计算用户浏览或访问过的推荐对象属于某个给定类的概率,然后依据概率将资源项目分类来建立用户对这些资源项目的偏好模型;使用决策树归纳作为用户模型学习技术的系统将用户偏好的获取过程表达成一棵决策树,用户从根节点开始,被引导来回答一系列问题。树的每个节点表示了决策点,所采取的方向取决于对问题的回答或者对可用数据的计算。一旦叶节点被达到,则可得到对用户偏好的完整描述;运用神经网络建模的算法,对系统对用户偏好的输入假设进行学习并调整网络连接权重,直到网络中的所有节点达到稳定激活状态。此时输出层中被激活的节点所对应的模式类,如感兴趣/不感兴趣类,即表示了系统识别的用户偏好;聚类将具有相似特征的项目或用户分组,使用这类技术的系统一般建立用户群组的综合模型。

3 推荐对象的建模

推荐系统应用于不同的领域,它推荐的对象也就各不相同,如何对推荐对象进行描述对推荐系统也有很重要的影响。和用户描述文件一样,要对推荐对象进行描述之前也要考虑以下几个问题:

- (1)提取推荐对象的什么特征,如何提取,提取的特征用于什么目的。
- (2)对象的特征描述和用户文件描述之间有关联。
- (3)提取到的每个对象特征对推荐结果会有什么影响。
- (4)对象的特征描述文件能否自动更新。

推荐对象的描述文件中的对象特征和用户的描述文件中的兴趣偏好进行推荐计算,获得推荐对象的推荐度,所以推荐对象的描述文件与用户的描述文件密切相关,通常的做法是用同样的方法来表达用户的兴趣偏好和推荐对象。

推荐系统推荐对象包括众多的领域,比如报纸、Usenet新闻、科技文档、Email,还有诸如音乐、电影等多媒体资源等等。不同的对象,特征也不相同,目前并没有一个统一的标准来进行统一描述,主要有基于内容的方法和基于分类的方法两大类方法。针对文档类对象的这两个表示方法给以分析。

基于内容的方法是从对象本身抽取信息来表示对象,使用最广泛的方法是用加权关键词矢量,该方法通过对一组文档的统计分析得出文档的特征向量。方法很多,比较简单的做法就是计算每个特征的熵,选取具有最大熵值的若干个特征;也可以计算每个特征的信息增量(Information gain),也就是计算每个特征在文档中出现前后的信息熵之差;还可以计算每个特征的互信息(mutual information),也就是计算每个特征和文档的相关性;还可使用 χ^2 统计方法。文献[28]的对比研究表明,信息增量方法和 χ^2 统计方法表现较好,但这两种方法的计算量比较大。

在完成文档特征的选取后,还得计算每个特征的权值,权

值大的对推荐结果的影响就大。目前使用最广泛的是TFIDF方法。

基于分类的方法是把推荐对象放入不同类别中,这样可以把同类文档推荐给对该类文档感兴趣的用户了。文本分类的方法有多种,比如朴素贝叶斯(Naive-Bayes), k 最近邻方法(KNN)和支持向量机(SVM)等。

对象的类别可以预先定义,也可以利用聚类技术自动产生,如文献[28]。许多研究表明:聚类的精度非常依赖于文档的数量,而且由自动聚类产生的类型可能对用户来说是毫无意义的,因此可以先使用手工选定的类型来分类文档,在没有对应的候选类型或需要进一步划分某类型时,才使用聚类产生的类型。

文本等对象特征提取技术相对比较成熟,但推荐系统的对象不一定具有文本特征或文本不足以作为描述^[29],尤其是网络上广泛存在的多媒体数据,自动化的特征提取方法需要结合多媒体内容分析领域的相关技术。

推荐系统推荐给用户的对象首先不能与用户看过的对象重复,其次也不能与用户刚刚看过的对象不是太形似或者太不相关,这就是所谓的模型过拟合问题(可扩展性问题)。出现这一问题的本质来自数据的不完备性,解决的主要的方法是引入随机性,使算法收敛到全局最优或者逼近全局最优,比如遗传算法^[30]等。文献[31-32]针对这一问题考察了被推荐的对象的相关性(relevant)和冗余性(redundancy),认为既要保证推荐的多样性,又不能与用户看过的对象重复或毫不相关。关于这一问题的研究是推荐系统研究的一个难点和重点。

推荐系统中出现新的对象时,推荐系统尤其是协同过滤系统中,新对象出现后必须等待一段时间才会有用户查看并进行评价,在此之前推荐系统无法对此对象进行分析和推荐,这就是推荐系统研究的另一个难点和重点——冷启动问题。目前,解决这一问题的方法就是从推荐方法上考虑,比如使用组合推荐方法来应付。对推荐对象的描述能动态更新会成为研究一个方向。

4 推荐算法模块

推荐算法(或叫推荐策略)是整个推荐系统中最核心和关键的部分,在很大程度上决定了推荐系统类型和性能的优劣,推荐策略的研究是推荐系统最为繁荣的部分,大量的论文和著作都关注了这个方面。目前,出现的推荐策略有很多,对其分类的标准也没有一个统一的标准,但受到大家公认的推荐策略基本包括以下几种:基于内容的推荐、协同过滤推荐、基于知识的推荐、基于网络结构的推荐、组合推荐及其他推荐。以下来介绍各种推荐策略及其优缺点。

4.1 基于内容的推荐

基于内容的推荐(content-based recommendation)方法源于信息获取领域^[32],是信息检索领域的重要研究内容。该方法是根据用户已经选择的对象,从推荐对象中选择其他特征相似的对象作为推荐结果。这一推荐策略首先提取推荐对象的内容特征,和用户模型中的用户兴趣偏好匹配,匹配度较高的推荐对象就可作为推荐结果推荐给用户。例如在进行音乐推荐时,系统分析用户以前选择的音乐的共性,找到用户的兴趣点。然后从其他音乐中选择和用户兴趣点相似的音乐推荐给用户。计算推荐对象的内容特征和用户模型中兴趣特征二者

之间的相似性是该推荐策略中一个关键部分^[4],如式(2)所示就是计算该相似性的一个函数。

$$u(c, s) = \text{score}(\text{userprofile}, \text{content}) \quad (2)$$

其中 score 的计算方法有很多种,比如使用最简单的向量夹角余弦的距离计算方法^[3],如式(3):

$$u(c, s) = \cos(Wc, Ws) = \frac{\sum_{i=1}^K W_{i,c} W_{i,s}}{\sqrt{\sum_{i=1}^K W_{i,c}^2} \sqrt{\sum_{i=1}^K W_{i,s}^2}} \quad (3)$$

计算所得的值按其大小排序,将最靠前的若干个对象作为推荐结果呈现给用户。

基于内容的推荐策略中的关键就是用户模型描述和推荐对象内容特征描述。其中对推荐对象内容进行特征提取,目前对文本内容进行特征提取方法比较成熟,如浏览页面的推荐、新闻推荐等。但网上的多媒体信息大量涌现,而对这些多媒体数据进行特征提取还有待技术支持,所以多媒体信息还没有大量用于基于内容的推荐。

基于内容的推荐的优点如下:

- (1)简单、有效,推荐结果直观,容易理解,不需要领域知识。
- (2)不需要用户的历史数据,如对对象的评价等。
- (3)没有关于新推荐对象出现的冷启动问题。
- (4)没有稀疏问题。

(5)比较成熟的分类学习方法能够为该方法提供支持,如数据挖掘、聚类分析等。

基于内容的推荐的缺点如下:

(1)该方法的广泛应用受到了推荐对象特征提取能力的限制较为严重。因为多媒体资源没有有效的特征提取方法,比如图像、视频、音乐等。即使文本资源,其特征提取方法也只能反映资源的一部分内容,例如,难以提取网页内容的质量,这些特征可能影响到用户的满意度。

(2)很难出现新的推荐结果。推荐对象的内容特征和用户的兴趣偏好匹配才能获得推荐,用户将仅限于获得跟以前类似的推荐结果,很难为用户发现新的感兴趣的信息。

(3)存在新用户出现时的冷启动问题。当新用户出现时,系统较难获得该用户的兴趣偏好,就不能和推荐对象的内容特征进行匹配,该用户将较难获得满意的推荐结果。

(4)对推荐对象内容分类方法需要的数据量较大。目前,尽管分类方法很多,但构造分类器时需要的数据量巨大,给分类带来一定困难。

(5)不同语言的描述的用户模型和推荐对象模型无法兼容也是基于内容推荐系统面临的又一个大的问题。

4.2 协同过滤推荐

协同过滤推荐(collaborative filtering recommendation)是推荐策略中最成功的策略,它于20世纪90年代开始研究并促进了整个推荐系统研究的繁荣。大量论文和研究都属于该类别。比如Grundy书籍推荐系统、Tapestry邮件处理系统,GroupLens、Ringo等推荐系统都属于该类推荐。

协同过滤推荐的基本思想借鉴了日常在选购商品、选择用餐饭店、选择看哪部电影等等的方法。如果自己身边的很多朋友都选购某种商品,那么自己就会很大概率的选择该商品。或者用户喜欢某类商品,当看到和这类商品相似商品并且其他用户对此类商品评价很高时,则购买的概率就会很

大。协同推荐的用户模型为用户-项目评价矩阵,如表1中表示 R_{ij} 第*i*用户对第*j*个项目的评分。

协同过滤推荐一般分为三类:基于用户的协同推荐(User-based Collaborative Filtering)(或基于内存的协同推荐(Memory-Based Collaborative Filtering))、基于项目的协同推荐(Item-Based Collaborative Filtering)和基于模型的协同推荐(Model-Based Collaborative Filtering)。

4.2.1 基于用户的协同推荐(UB-CF)

该推荐策略又叫基于内存的推荐(MB-CF),它的基本思想是用户选择某个推荐对象是基于朋友的推荐。也就是说如果一些用户对某些推荐对象的评分比较相似,则说明这些用户的兴趣偏好相似,那么他们对其他推荐对象的评分应该也是相似的。所以协同过滤推荐首先找到和目标用户兴趣偏好相似的最近邻居,然后根据他的最近邻居对推荐对象的评分来预测目标用户对未评分的推荐对象的评分,选择预测评分最高的若干个推荐对象作为推荐结果反馈给用户。该推荐过程如图3所示。




图3 基于用户的协同推荐过程

基于用户的协同推荐主要工作有两个,首先是查询最近邻居,然后就是产生推荐。其核心就是最近邻居查询。要找到最近邻居就要度量用户之间的相似性,相似度越高,用户就越相近。把用户*i*和用户*j*之间的相似性记为 $\text{sim}(i, j)$ 。每个用户对推荐对象的评分可看作是一个*m*维向量,度量用户间的相似度就可以用不同的*m*维向量间的相似度进行度量,如图4所示,度量用户间相似性的方法主要有如下三种方法^[33-34]:

	对象1	对象k	对象n
① 用户1	$R_{1,1}$	$R_{1,k}$	$R_{1,n}$
.....
.....
② 用户m	$R_{m,k}$	$R_{m,n}$

注:①用户1和用户m的相似度,②对象1和对象k的相似度。

图4 用户评分矩阵

(1)余弦相似性(Cosine):设用户*i*和用户*j*在*m*维对象空间上的评分表示为向量*i*,*j*,则 $\text{sim}(i, j)$ 的相似性计算方法如式(4):

$$\text{sim}(i, j) = \cos(i, j) = \frac{i \cdot j}{\|i\| \|j\|} \quad (4)$$

(2)相关相似性(Correlation):设用户*i*和用户*j*共同评分的对象集合用 I_{ij} 表示,则用户*i*和用户*j*之间的相似性通过Pearson相关系数度量,如式(5)所示:

$$\text{sim}(i, j) = \frac{\sum_{c \in I_{ij}} (R_{i,c} - \bar{R}_i)(R_{j,c} - \bar{R}_j)}{\sqrt{\sum_{c \in I_{ij}} (R_{i,c} - \bar{R}_i)^2} \sqrt{\sum_{c \in I_{ij}} (R_{j,c} - \bar{R}_j)^2}} \quad (5)$$

其中 $R_{i,c}$ 表示用户 i 对推荐对象 c 的评分, \bar{R}_i 和 \bar{R}_j 分别表示用户 i 和用户 j 的平均评分。

(3)修正余弦函数弦相似性(Adjusted Cosine):在余弦相似度量方法中没有考虑不同用户的评分尺度问题,修正余弦相似度量方法通过减去用户对推荐对象的平均评分改善上述缺陷。设用户 i 和用户 j 共同评分过的推荐对象集合用 $I_{i,j}$ 表示, I_i 和 I_j 分别表示用户 i 和用户 j 评分过的推荐对象集合,则用户 i 和用户 j 之间的相似性 $sim(i,j)$ 如式(6)所示:

$$sim(i,j) = \frac{\sum_{c \in I_{i,j}} (R_{i,c} - \bar{R}_i)(R_{j,c} - \bar{R}_j)}{\sqrt{\sum_{c \in I_i} (R_{i,c} - \bar{R}_i)^2} \sqrt{\sum_{c \in I_j} (R_{j,c} - \bar{R}_j)^2}} \quad (6)$$

其中 $R_{i,c}$ 表示用户 i 对推荐对象 c 的评分, \bar{R}_i 和 \bar{R}_j 分别表示用户 i 和用户 j 的平均评分。

通过上面提出的相似度量方法得到目标用户的最近邻居,下一步需要产生相应的推荐。设用户 u 的最近邻居集合 NN_u 表示,则用户 u 对推荐对象 i 的预测评分 $P_{u,i}$ 可以通过用户 u 对最近邻居集合 NN_u 中项的评分得到,计算方法如下^[35-36]如式(7)所示:

$$P_{u,i} = \bar{R}_u + \frac{\sum_{n \in NN_u} sim(u,n) * (R_{n,i} - \bar{R}_n)}{\sum_{n \in NN_u} |sim(u,n)|} \quad (7)$$

其中 $sim(u,n)$ 表示 u 和用户 n 之间的相似性, $R_{n,i}$ 表示用户 n 对推荐对象 i 的评分。 \bar{R}_u 和 \bar{R}_n 分别表示用户 u 和用户 n 对推荐对象的平均评分。

通过上述方法预测用户对所有未评分的推荐对象的评分,然后选择预测评分最高的前若干推荐对象作为推荐结果反馈给当前用户。

4.2.2 基于项目的协同过滤推荐(IB-CF)

如果基于用户的协同推荐的依据是基于朋友的推荐的话,基于项目的协同推荐是基于用户对推荐对象品牌的信任而进行的推荐。基于项目的协同推荐是基于这样一个假设:如果大部分用户对一些推荐对象的评分比较相似,则当前用户对这些项的评分也比较相似。就好像很多用户对某个品牌比较信任,则其他用户就比较容易选择该品牌的产品。

基于项目的协同推荐的基本思路^[37-38]就是首先找到目标对象的最近邻居,由于当前用户对最近邻居的评分与对目标推荐对象的评分比较类似,所以可以根据当前用户对最近邻居的评分预测当前用户对目标推荐对象的评分,然后选择预测评分最高的若干个目标对象作为推荐结果呈现给当前用户。

基于项目的协同推荐的主要工作有两个,首先是查询目标推荐对象的最近邻居,然后产生推荐。其核心是推荐对象的最近邻居查询。推荐过程如图3所示。

推荐对象最近邻居的查询就是计算推荐对象之间的相似性。度量推荐对象的相似性就是计算如图4中所示的向量之间的相似性,而计算对象之间的相似性的方法和计算用户间的相似相似,主要有也是三种方法,分别是余弦相似性、相关相似性(Correlation)和修正余弦函数弦相似性(Adjusted Cosine)^[34],仅仅在计算时选取的向量是如图4中的列构成的向量。

找到目标推荐对象的最近邻居后,就可以利用最近邻居产生推荐了。设目标对象 T 的最近邻居集合用 NB_T 表示,则

用户 u 对目标 T 的预测评分 $P_{u,T}$ 可以通过目标对象的最近邻居的评分得到,计算方法如式(8):

$$P_{u,T} = \bar{R}_T + \frac{\sum_{n \in NB_T} sim(T,n) * (R_{u,n} - \bar{R}_n)}{\sum_{n \in NB_T} |sim(T,n)|} \quad (8)$$

其中 $sim(T,n)$ 表示目标对象 T 与最近邻居 n 之间的相似性, $R_{u,n}$ 表示用户 u 对对象 n 的评分。 \bar{R}_T 和 \bar{R}_n 分别表示对象 T 和对象 n 的平均评分。通过式(8)可以预测用户对未评分对象的评分,从而选择预测评分最高的若干个对象作为推荐结果反馈给当前用户。

4.2.3 基于模型的协同推荐(MB-CF)

这类方法是利用用户 c 对众多对象的评分来得到一个用户 c 的模型^[39-42],进而对某对象预测打分。和上述两种协同推荐的不同在于对已有数据应用统计和机器学习的方法得到模型进行预测的。Bereese^[35]等出了一个基于概率的算法,其形式化描述如式(9)所示:

$$R_{c,s} = E(R_{c,s}) = \sum_i i \times pr(R_{c,s} = i | R_{c,s'}, s' \in S_c) \quad (9)$$

这一方法中,建立用户模型是核心,常用的方法有机器学习方法^[43]、统计模型^[41]、贝叶斯模型^[40]、概率相关模型^[43]、线性回归模型^[38]和最大熵模型^[42]。另外还有一些其他的模型,例如 Shanideng^[26]基于 Markov 链的模型、潜层语义分析模型、语义生成模型, Yu^[44]等还提出了输入选择技术,解决给予模型的算法需要对大规模数据进行学习的问题。

协同过滤的优点^[34,45]:

(1)复杂的非结构化的对象可以应用协同过滤,比如电影、音乐、图像等推荐对象。

(2)善于发现用户新的兴趣点^[46]。协同过滤可以发现内容上完全不相似的资源,用户对推荐信息的内容事先是预料不到的。

(3)不需要专业知识即可进行推荐。

(4)随着用户的增多,其推荐性能会不断提升。

(5)以用户为中心自动进行推荐。

协同过滤的缺点:

(1)存在冷启动问题。新进入的用户由于得不到他们的兴趣偏好而无法获得推荐,新的推荐项目由于没有用户评价它就得不到推荐,这就是冷启动问题。冷启动问题是推荐系统研究的难点和重点。

(2)存在稀疏性问题。由于用户数目的大量增长,而且用户之间选择存在差异性,使得用户的评分差别非常大。同时推荐对象的数量也大量增长,使得大量的推荐对象没有经过用户的评价。这些会导致部分用户无法获得推荐,部分推荐对象得不到推荐,这就是稀疏性问题。

(3)系统开始时推荐质量差及推荐质量取决于历史数据集。

5 基于社会网络分析方法的推荐

基于社会网络分析方法(Social Network Analysis, SNA)的推荐把社会网络分析理论应用于推荐系统的一类方法,目前该方法研究是协同过滤推荐的延伸。

社会网络(social network)是为达到特定的目的,人与人之间、组织之间等进行信息交流时形成的关系网。该网由结点和结点间的连线组成,结点可以人、组织、计算机等实体,连

线表示这些实体之间的信息交互。社会网络分析(SNA)是对社会网络进行研究的一个重要工具,它为多结点之间的关系进行描述,并对其价值进行估量的一个工具。目前该方法被广泛应用于其他很多跨学科领域,例如信息推荐、Web超链分析等。

用户在购买或浏览网页信息时,形成用户和产品之间的链接关系,从而形成社会网络关系,通过社会网络分析方法可以考察结点之间(用户和用户之间或产品之间)的相关性,并依此进行推荐^[47-48]。文献[49-50]利用结点之间的关系计算结点之间信任度,利用它们之间的信任度进行推荐可以比一般的协同推荐获得更高推荐效果。

6 基于网络结构的推荐策略

基于网络结构的推荐策略是一种较新的推荐策略,该策略中不用考虑用户和推荐对象的内容,而是把用户和推荐对象抽象为节点,而用户选择了某一推荐对象就会在用户和对象之间存在选择关系,该策略认为信息就隐藏在该选择关系中。该策略由周涛、Huang、刘建国等人提出。

文献[51-54]中,周涛、Huang等认为在一个由 m 个用户和 n 个对象构成的推荐系统中,如果用户 i 选择过对象 j ,则在用户 i 和对象 j 之间存在一条边 $a_{ij}=1$,否则不存在该边,其中 $i=1, 2, \dots, m; j=1, 2, \dots, n$,所以系统可以表示为一个 $m+n$ 个节点组成的二部分图(bipartite network),而推荐算法的目的就是对任意的用户,能把他没有选择的对象按照其喜好程度排序,并把排序靠前的对象推荐给该用户。周涛、Huang等在用户—产品二部分图的基础上把物理学理论和复杂网络的理论应用于推荐算法中,分别给出了不同的推荐策略。

周涛等人在文献[51-52]中提出了一种基于资源分配的全新的推荐算法,该算法中认为对象都具有某种可分的资源,而且会把资源分配给自己喜欢的对象。如果用 w_{ij} 表示对象 j 愿意分配给对象 i 的资源配额, w_{ij} 可表示为如式(10):

$$w_{ij} = \frac{1}{k_j} \sum_{l=1}^m \frac{a_{il} a_{jl}}{k_l} \quad (10)$$

其中 k_j 为对象 j 的度, k_l 表示用户 l 的度。

对于具有 n 个对象的系统,当用户选择了某个对象,则该对象的初始资源为1,否则为零,如此可得任意目标用户的 n 维矢量,即为该用户的初始资源分配构型,记为 f ,该构型反映用户的个性化信息。根据资源配额的计算,可知最终的资源分配矢量如式(11):

$$f' = wf \quad (11)$$

对于用户没有看过的所有产品,按照 f' 中的值排序,值越大说明用户就越喜欢,排在前面的就可推荐给用户。

周涛等人认为对同样的用户,推荐冷门对象比推荐热门的对象更显示推荐系统的优越,比如众所周知的好莱坞大片,即使不做推荐,用户可以通过其他很多途径知道该片,而冷门的电影是用户喜欢的,且冷门的电影数量较大,由于没有媒体宣传,如果没有推荐,用户很难获得其信息,所以推荐冷门对象更有意义。而通过降低大度对象的推荐能力提高推荐的精确度,可以提高冷门对象的推荐能力。

同时,周涛等认为去除重复属性也可提高算法的精确度,从原来关联矩阵中去除二阶甚至与高阶的关联,也可以提高

算法的精确性。

基于网络结构的推荐策略中另一分支就是把网络结构信息应用于经典协同过滤策略,产生出优于经典协同过滤的算法来。例如文献[54]中刘建国和汪秉宏利用资源分配原理计算用户之间的相似性,进而利用协同过滤算法想用户进行个性化推荐,其推荐结果的平均准确度得到了较大提高,其用户相似性的度量如式(12):

$$s_{ij} = \frac{i}{k(u_i)} \sum_{l=1}^n \frac{a_{il} a_{jl}}{k(o_l)} \quad (12)$$

其中 $k(o_l)$ 为用户 o_l 的度。

同时文献[55]中刘润然等利用用户和对象的度信息提出了另外的用户相似度计算方法,也得到了比经典协同过滤算法更好的效果。文献[56-57]把热传导和物质扩散理论应用于推荐算法中,也获得了明显好于经典协同过滤算法的效果。文献[7]中Huang等把扩散动力学应用于二部分图中,部分地解决了数据稀疏性的问题。

文献[57]在用户—对象二部分图的基础上,把复杂网络的理论应用于基于项目的协同推荐算法,并且利用BA网络的优先扩展(Preferential attachment)的特性来优先当前潮流对象进行推荐,还把线性腐蚀时间用于推荐对象的计算,从而考虑流行对象的时间问题,也获得较好推荐效果。

7 混合推荐

各种推荐方法都有各自的优缺点,在实际应用中可以针对具体问题采用推荐策略的组合进行推荐,即所谓的组合推荐。组合推荐的目的是通过组合不同的推荐策略,达到扬长避短的目的,从而产生更符合用户需求的推荐。理论上讲可以有多种的推荐组合方法,但目前研究和应用最多的组合推荐是把基于内容的推荐和系统过滤推荐的组合^[58-61]。把它们组合方法根据应用场景不同而不同,主要混合思路有两种:

(1)推荐结果混合:这是一种最简单的混合方法,就是分别是用两种或多种推荐方法产生推荐结果,然后采用某种算法把推荐结果进行混合而得到最终推荐。如何从众多推荐结果中选择用户需要的推荐结果成为该算法的一个重要研究点。比如采用投票机制来组合推荐结果^[60],采用一定的标准对两者产生的推荐结果判断^[61],从而选择其中之一,利用预测打分的线性组合进行推荐^[60-61],文献[62]选择一个与用户过去的打分相一致的结果进行推荐,也可计算两个推荐结果的可信度从而选择一个^[1]等等。

(2)推荐算法的混合:以某种推荐策略为框架,混合另外的推荐策略,例如协同推荐的框架内混合基于内容的推荐^[63-66](或相反)、基于协同推荐的框架内混合基于网络结构的推荐^[54,56],社会网络分析法的推荐框架内混合基于内容的推荐^[67-68],基于网络结构的推荐和基于社会网络分析法的推荐的混合等。

还有一些其他的推荐方式,首先就是基于关联规则分析法,Agrawal^[69]等提出了Apriori算法进行关联规则分析,Han^[70]等对该算法进行了改进。另外还有基于用户购买行为预测产品的出售情况。

8 推荐系统的体系结构

推荐系统的体系结构研究的重要问题就是用户信息收集

和用户描述文件放在什么地方^[71],服务器还是客户机上,或者是处于二者之间的代理服务器上。

最初的推荐系统都是基于服务器端的推荐系统,基本结构如图5。在这类推荐系统中,推荐系统与Web服务器一般共享一台硬件设备。在逻辑上,推荐系统要的用户信息收集和建模都依赖于Web服务器^[72-74]。




图5 基于服务器端的推荐系统结构

由此可知,基于服务器端的推荐系统存在的问题主要包括:

(1)个性化信息的收集完全由Web服务器来完成,受到了Web服务器功能的限制^[71]。

(2)增加了Web服务器的系统开销^[71]。

(3)对用户的隐私有极大威胁^[75-77]。无论是推荐系统的管理者还是入侵推荐系统的人员都能方便地获取存放在服务器上的用户数据。由于用户的个人数据是有很高价值的,接触到用户数据的部分人会出卖用户数据或把用户数据用于非法用途。

基于上述问题,文献[78-81]中提出基于客户端的推荐系统,基于客户端的推荐系统中,用户信息的收集和建模都在客户端完成。客户端推荐系统的体系结构如图6所示。




图6 基于客户端的推荐系统结构

典型的客户端个性化服务系统有斯坦福大学的LIRA、麻省理工学院的Letizia、加州大学的Syskill&Webert、卡内基·梅隆大学的Personal Web-Watcher等。

基于客户端的推荐系统有如下优点:

(1)由于用户的信息就在本地收集和處理,因而不但能够获取丰富准确的用户信息以构建高质量的用户模型^[74]。

(2)少量甚至没有用户数据存放在服务器上,Web服务器不能访问和控制用户的数据,能比较好地保护用户的隐私。

(2)用户更愿意向推荐系统提供个人信息,从而提高推荐系统的推荐性能。因为基于客户端的推荐系统中的用户数据存储在用户本地客户机上,用户对数据能够进行自行控制。

基于客户端的推荐系统有一定缺点:

(1)用户描述文件的形成、推荐策略的应用都依赖于所有用户数据分析的基础上进行的,而基于客户端的推荐系统较难获取其他用户的数据,用户描述文件较难得到,协同推荐策略实施也较难,所以推荐系统要重新设计,尤其是推荐策略必须进行修改。

(2)个性化推荐处理过程中用户的数据资料还需要部分的传给服务器,存在隐私泄露的危险,需要开发安全传输平台进行数据传输。

推荐系统另一种体系结构就是基于代理的推荐系统。其结构如图7所示。在这一结构中,用户信息的收集、用户建模和推荐服务都在代理端实现。典型的代理端个性化服务系统有明尼苏达大学的GroupLens、斯坦福大学的Fab^[58]等。

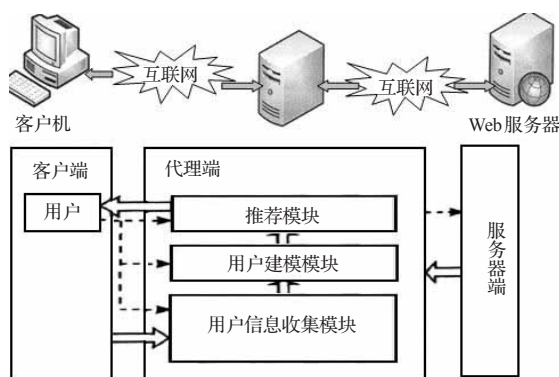


图7 基于代理的推荐系统

基于代理的推荐系统中用户信息都传给了代理,代理能获得所有用户的资料而形成用户描述文件。但由于用户信息都要传给代理端,所以存在用户的信息泄露等隐私问题。

无论是基于客户端的推荐系统还是基于服务器的推荐系统,都是把用户描述文件集中存在某一个地方,都存在用户数据被侵害的危险。文献[82-86]中阐述了分布式推荐系统,在分布式推荐系统中,用户描述文件存放在不同的地方,可以大大提高用户数据的安全性。

9 推荐系统性能评价

评价推荐系统性能的好坏通常用推荐的精确度和推荐效率两个指标进行衡量。

精确度的衡量最典型的指标^[3,33]是平均绝对误差(Mean Absolute Error, MAE)和平均平方误差(Mean Squared Error, MSE)以及标准平均误差(Normalized Mean Absolute Error, NMAE)。它们的计算形式分别如式(13)和(14)以及(15)所示。

$$MAE = \frac{1}{n} \sum_{i=1}^n |p_{ia} - r_{ia}| \quad (13)$$

$$RMSE = \sqrt{\frac{1}{n_i} \sum_{i=1}^n |p_{ia} - r_{ia}|^2} \quad (14)$$

$$NMAE = \frac{MAE}{r_{\max} - r_{\min}} \quad (15)$$

其中 n 为系统中用户 i 打分产品的个数, p_{ia} 和 r_{ia} 分别为预测打分和实际打分。 n_i 为系统中用户-产品对的个数。 r_{\min} 和 r_{\max} 分别为用户打分区间的最小值和最大值。

召回率(recall)和精确率(precision)也可以用来衡量推荐的准确度。召回率定义为推荐列表中用户喜欢的产品与系统中用户喜欢的所有产品的比率。计算方法如式(16)所示:

$$R = \frac{N_{rs}}{N_r} \quad (16)$$

准确率:推荐列表中用户喜欢的产品和所有被推荐产品的比率,计算方法如式(17)所示:

$$P = \frac{N_{rs}}{N_s} \quad (17)$$

其中 N_{rs} 推荐列表中用户喜欢的产品个数, N_r 用户喜欢的所有产品的个数, N_s 为所有被推荐产品的个数。

召回率和精准率评价系统时的最大问题在于它们必须一起使用才能全面评价算法的好坏,文献[63]综合二者提出了一个 F 指标,计算方法如式(18):

$$F = \frac{2PR}{P+R} \quad (18)$$

其中 P 和 R 分别是准确率和召回率。

文献[51-52]等中,周涛等提出了平均排队值(Ranking score)来度量算法的精确度。比如 L_i 个产品是用户 i 没有选择过的对象,并且已经根据用户喜好进行了排序,如果用户 i 选择了对象 j ,而对象 j 在排序时被排在 R_{ij} 位,则认为 (i,j) 的相对位置为:

$$r_{ij} = \frac{R_{ij}}{L_i} \quad (19)$$

越是精确的算法 r_{ij} 的值越小。将所有用户—对象对 (i,j) 的相对位置求平均,就是平均排队值,该值可以量化评价算法的精确度。

Pearson 关联、Speaman 关联和 Kendall's Tau 可以分析系统打分排序与用户实际的打分排序之间的关联关系,可以评价系统的准确度。Pearson 关联定义如式(20):

$$C = \frac{\sum (x - \bar{x})(y - \bar{y})}{n \sqrt{\prod (x - \bar{x})^2} \sqrt{\prod (y - \bar{y})^2}} \quad (20)$$

其中 x 和 y 为两个向量中对应位置的打分值, n 是向量维度。Speam an 关联和 Pearson 关联一样,就是 x 和 y 变成了相应的排序位置。

Kendall's Tau 是另外一种计算排名相关性的方法,其值越大预测效果越好。计算方法如式(21):

$$Tau = \frac{C - D}{\sqrt{(C + D + TR)(C + D + TP)}} \quad (21)$$

其中 C 为预测正确的喜好偏序数, D 为预测错误的喜好偏序数, TR 为用户打分相同的产品, TP 为具有相同预测值的产品数。

另外距离标准化指标^[58, 87]、半衰期效用指标^[35, 88]和 ROC 曲线^[89-90],也用于系统推荐准确度的评价,也取得较好的效果。

同时,周涛等人新提出了几个衡量推荐算法的衡量指标,也很值得研究。第一个是推荐多样性的衡量,即一个好的推荐系统应能够向用户推荐不同类型的对象,而不是同类型的对象。其中平均加权距离 S 作为衡量推荐列表的外部多样性指标,比如推荐列表的长度为 L ,用户 i 和用户 j 的推荐类表中相同项的数量为 Q ,则加权平均距离(Hamming distance)定义如式(22):

$$H_{ij} = 1 - \frac{Q}{L} \quad (22)$$

将该值得平均作为衡量推荐类表外部多样性的指标,如式(23):

$$S = \frac{1}{m(m-1)} \sum_{i \neq j} H_{ij} \quad (23)$$

其中 m 为用户的数量。推荐系统的个性化越高,该值就越大。用户 u_i 推荐列表的内部相似性如式(24):

$$I_i = \frac{1}{L(L-1)} \sum_{i \neq j} s_{ij}^o \quad (24)$$

其中 s_{ij}^o 是对象 o_i 和 o_j 之间的相似度。整个系统的内部相似性定义如式(25):

$$I = \frac{1}{m} \sum_{i=1}^m I_i \quad (25)$$

该值越小说明推荐的多样性更好。

第二个衡量推荐系统的新指标是推荐冷门对象的能力。一个推荐系统推荐出用户喜欢的冷门对象,比推荐出大众都喜欢的对象更有吸引力。而对象的受欢迎程度依靠平均度 $\langle k \rangle$ 来衡量,单纯的平均度是不能保证 S 和 I 也能取得较好效果,所以周涛等人认为高 S 值,低 I 值和低平均度的推荐算法就是较好的推荐算法。

对推荐系统进行性能测试时,通常的做法是把数据集分割为训练集和测试集。推荐算法的模型在训练集上进行学习和参数调整,然后在测试集合上计算精确度和运行效率,从而达到评测目的。

推荐系统在进行研究和测试的时候使用的数据集,目前主要有以下几个数据集:

MovieLens、EachMovie 和 Netflix 三个数据集包含的数据是电影。BookCrossing 包括了书籍类数据。Jester Joke 包括的数据是笑话。Usenet Newsgroups 包括的数据是新闻组的用户浏览数据。UCI 知识库存储了大量用于模型训练的样本。

10 推荐系统研究的重点、难点及发展方向

推荐系统经过了一段时间的发展,关于推荐相关的问题,出现了一些重点和难点问题得到了研究者的关注,也是未来研究的热点问题。

(1) 用户兴趣偏好获取方法和推荐对象的特征提取方法的研究

目前的推荐系统中实际上较少使用了用户和推荐对象的特征,即使使用很广泛的协同推荐使用的是用户的评分。主要是用户兴趣偏好的获取方法和推荐对象特征提取方法不是很适用,需要引入更精确适用的用户和对象特征。

(2) 推荐系统的安全性研究

进行协同推荐时需要掌握用户的兴趣偏好等用户信息,但用户担心个人数据得不到有效保护而不愿暴露个人信息^[77, 86],这是协同推荐长期存在的一个问题。既能得到用户信息而提高推荐系统性能,又能有效保护用户信息将是未来推荐系统的一个研究方向^[91-92]。同时一些不法的用户为了提高或降低某些对象的推荐概率,恶意捏造用户评分数据而达到目的,这也是推荐系统存在的一个安全问题,被称为推荐攻击^[93-96]。检测并能预防推荐攻击也将是未来一个研究方向。

(3) 基于复杂网络理论及图方法的推荐系统研究

复杂网络理论和图方法同协同推荐存在契合点,在文献[3, 97]中网络视频推荐问题转化为热量散播平衡态网络上的谱图分割问题,通过设计长尾发现的推荐策略引导用户发现潜在的感兴趣的网络视频。利用复杂网络理论和图方法进行

行推荐也是推荐系统研究的一个方向。

(4) 推荐的多维度研究

目前的推荐研究都是基于用户-对象二维空间进行研究的,但是用户选择某个对象以及对对象的评分在不同的情况下会有所不同,也就是推荐使用的特征维度会有所不同,研究推荐的多维度也是未来的一个研究方向。

(5) 稀疏性和冷启动研究

稀疏性和冷启动问题是困扰推荐系统很长时间了,包括经典协同过滤算法和新出现的基于网络结构的推荐算法都存在该问题。有很多研究者对这一问题进行研究并提出解决办法,但该问题依然存在,还需要对其进行研究。

(6) 推荐系统性能评价指标的研究

用户对算法准确度的敏感度、算法对不同领域的普适性、广义的质量评价方法等都是未来推荐系统性能评价要进行研究的目标。

参考文献:

- [1] 张娜. 电子商务环境下的个性化信息推荐服务及应用研究[D]. 合肥: 合肥工业大学, 2007.
- [2] Resnick P, Varian H R. Recommender systems[J]. Communications of the ACM, 1997, 40(3): 56-58.
- [3] 许海玲. 互联网推荐系统比较研究[J]. 软件学报, 2009, 20(2): 350-362.
- [4] Adomavicius G, Tuzhilin A. Toward the next generation of recommender systems: A survey of the state-of-the-art and possible extensions[J]. IEEE Trans on Knowledge and Data Engineering, 2005, 17(6): 734-749.
- [5] Sung H H. Helping online customers decide through Web personalization[J]. IEEE Intelligent Systems, 2002, 9: 34-43.
- [6] 曾春, 邢春晓, 周立柱. 个性化信息服务技术综述[J]. 软件学报, 2002, 13(10): 1952-1961.
- [7] 王巧荣, 赵海燕, 曹健. 个性化服务中的用户建模技术[J]. 小型微型计算机系统, 2011, 32(1): 39-46.
- [8] Zhao Jinghe, Liu Guiquan. Automatic modeling based on interest clustering[J]. AI Commun, 2001, 14(3): 129-147.
- [9] Zhang Yulian, Wang Quan. User profile mining of combining Web behavior and content analysis[J]. New Technology of Library and Information Service, 2007(6): 52-55.
- [10] Bonnefoy D, Bouzid M, Lhuillier N, et al. "More like this" or "not for me": delivering personalized recommendations in multiuser environments[C]//Conati C, McCoy K, Paliouras G. User Modeling 2007. Berlin, Heidelberg: Springer-Verlag, 2007, 4511: 87-96.
- [11] Adomavicius G, Sankaranarayanan R, Shahana S, et al. Incorporating contextual information in recommendation systems using a multidimensional approach[J]. ACM Transactions on Information Systems, 2005, 23(1): 103-145.
- [12] Weng S S, Lin B S, Chen W J. Using contextual information and multidimensional approach for recommendation[J]. Expert System with Applications, 2009(36): 1268-1279.
- [13] Maloof M, SMichalski R. Selecting examples for partial memory learning[J]. Machine Learning, 2000(41): 27-52.
- [14] Xu Bin, Liu Sai, Kang Lishan, et al. Information retrieval technique based on genetic algorithm[J]. Computer Engineering, 2004, 30(9): 74-75.
- [15] Joachims T, Freitag D, Mitchell T. WebWatcher: a tour guide for the world wide web[C]//Proceedings of the 1997 IJCAI, Japan, 1997: 770-775.
- [16] Miller B N, Albert I, Lam S K, et al. MovieLens unplugged: Experiences with an occasionally connected recommender system[C]//Proc of the Int'l Conf on Intelligent User Interfaces. New York: ACM Press, 2003: 263-266.
- [17] Zaiane O R, Xin M, Han J. Discovering Web access patterns and trends by applying OLAP and DATA mining technology on Web logs[C]//Proceedings of the IEEE International Forum on Research and Technology Advances in Digital Libraries. Los Alamitos: IEEE CS Press, 1998: 19-29.
- [18] Paliouras G, Papatheodorou C, Karkaletsis V, et al. Clustering the users of large web sites into communities[C]//Proceedings of the 17th International Conference on Machine Learning. San Francisco: Morgan Kaufmann Publishers, 2000: 719-726.
- [19] Nanopoulos A, Manolopoulos Y. Mining patterns from graph traversals[J]. Data and Knowledge Engineering, 2001, 37(3): 243-266.
- [20] Schwab I, Pohl W, Koychev I, et al. Learning to recommend from positive evidence[C]//Riecken D, Benyon D, Lieberm H. Proceedings of International Conference on Intelligent User Interfaces, New York, 2000: 241-247.
- [21] Ying Xiaomin. The research on user modeling for internet personalized services[D]. National University of Defense Technology, 2003.
- [22] Claypool M, Le P, Waseda M, et al. Implicit interest indicators[C]//Proceedings of the ACM Intelligent User Interfaces Conference (IUI). New York: ACM Press, 2001: 14-17.
- [23] Yan Duanwu. Research on knowledge service oriented intelligent recommendation system[D]. Nanjing University of Science and Technology, 2007.
- [24] Crabtree B, Soltysiak S J. Identifying and tracking changing interests[J]. International Journal of Digital Libraries, 1998, 2(1): 38-53.
- [25] Maloof M, SMichalski R. Selecting examples for partial memory learning[J]. Machine Learning, 2000(41): 27-52.
- [26] Smyth B, Bradley K, Rafter R. Personalization techniques for online recruitment services[J]. ACM New York Communications of the ACM-The Adaptive Web New York, 2002, 45(5): 39-40.
- [27] Lin Baolin, Lan Yun, Zhang Yiying. A method to optimize user model based on dynamic genetic algorithm[J]. Computer Engineering and Applications, 2006, 42(14): 200-203.
- [28] 赵鹏, 耿焕同, 王清毅, 等. 基于聚类 and 分类的个性化文章自动推荐系统的研究[J]. 南京大学学报: 自然科学版, 2006, 42(5): 512-518.
- [29] Shardanand U, Maes P. Social information filtering: Algorithms for automation "Word of Mouth"[C]//Proc of the Conf on Human Factors in Computing Systems. New York: ACM Press, 1995: 210-217.
- [30] Sheth B, Maes P. Evolving agents for personalized information filtering[C]//Proc of the 9th IEEE Conf on Artificial Intelligence for Applications, 1993: 345-352.
- [31] Billsus D, Pazzani M. User modeling for adaptive new access[J]. User Modeling and User Adapted Interaction, 2002, 10(2): 147-180.

- [32] 刘玮.电子商务系统中的信息推荐方法研究[J].情报科学,2006,24(2):300-303.
- [33] Sarwar B, Karypis G, Konstan J, et al. Item-based collaborative filtering recommendation algorithms[C]//Proceedings of the 10th International Conference on World Wide Web. New York: ACM Press, 2001: 285-295.
- [34] 邓爱林.电子商务推荐系统关键技术研究[D].上海:复旦大学,2003.
- [35] Breese J, Hecherman D, Kadie C. Empirical analysis of predictive algorithms for collaborative filtering[C]//Proceedings of the 14th Conference on Uncertainty in Artificial Intelligence, 1998: 43-52.
- [36] Sarwar B M, Karypis G, Konstan J A, et al. Application of dimensionality reduction in recommender system—a case study[C]//Proceedings of ACM WebKDD 2000 Workshop, 2000.
- [37] Karypis G. Evaluation of item-based top-*n* recommendation algorithms[C]//Proceedings of the 10th International Conference on Information and Knowledge Management, 2001.
- [38] Sarwar B, Karypis G, Konstan J, et al. Item based collaborative filtering recommendation algorithms for e-commerce[C]//Proceedings of the ACM EC00 Conference, 2000, 40(3): 158-167.
- [39] 陈君,唐雁.基于Web社会网络的个性化Web信息推荐模型[J].计算机科学,2006,33(4):185-193.
- [40] Chien Y H, George E I A. Bayesian model for collaborative filtering[C]//Proc of the 7th Int'l Workshop on Artificial Intelligence and Statistics. San Francisco: Morgan Kaufmann, 1999.
- [41] Ungar L H, Foster D P. Clustering methods for collaborative filtering[C]//Proc of the Workshop on Recommendation Systems. Menlo Park: AAAI Press, 1998: 112-125.
- [42] Pavlov D, Pennock D A. A maximum entropy approach to collaborative filtering in dynamic, sparse, high-dimensional domains[C]//Proc of the 16th Annual Conf on Neural Information Processing Systems, 2002.
- [43] Getoor L, Sahami M. Using probabilistic relational models for collaborative filtering[C]//Proc of the Workshop Web Usage Analysis and User Profiling under KDD'99. San Diego: [s.n.], 1999.
- [44] Yu K, Xu X, Tao J, et al. Instance selection techniques for memory-based collaborative filtering[C]//Proc Second SIMA Int' iConf Data Mining, SDM'02, 2002.
- [45] 刘庆华.个性化推荐技术及其在电子商务中的应用[D].南昌:南昌大学,2007.
- [46] 庞秀丽,冯玉强,姜维.电子商务个性化文档推荐技术研究[J].中国管理科学,2008,16(专辑):581-586.
- [47] Zheng Rong, Provost F, Ghose A. Social network collaborative filtering[D]. Center for Digital Economy Research, Stern School of Business, New York University, 2007.
- [48] Kautz H, Selman B, Shah M. Combining social networks and collaborative filtering[J]. Communication of the ACM, 1997, 40(3): 62-65.
- [49] Golbeck J. Generating predictive movie recommendations from trust in social networks[C]//Proceedings of the Fourth International Conference on Trust Management, 2006.
- [50] Massa P, Avesani P. Trust-aware collaborative filtering for recommender systems[C]//Proc of Fourth International Conference on Trust Management, Pisa, Italy, 2006.
- [51] Zhou T, Ren J, Medo M, et al. Bipartite network projection and personal recommendation[J]. Phys Rev E, 2007, 76.
- [52] Zhou T, Jing L L, Su R Q, et al. Effect of initial configuration on network-based recommendation[J]. Europhys Lett, 2008, 81.
- [53] Huang Z, Chen H, Zeng D. Applying associative retrieval techniques to alleviate the sparsity problem in collaborative filtering[J]. IEEE Trans on Information Systems, 2004, 22(1): 116-142.
- [54] Zhang Y C, Blattner M, Yu Y K. Heat conduction process on community networks as a recommendation model[J]. Phys Rev Lett, 2007, 99.
- [55] Zhang Y C, Medo M, Ren J, et al. Recommendation model based on opinion diffusion[J]. Europhys Lett, 2007, 80.
- [56] Zhou T, Su R Q, Liu R R, et al. Accurate and diverse recommendations via elimination redundant correlations[J]. New Journal of Physics, 2009, 11.
- [57] Zhanin M M, Cano P, Buldu J M, et al. Complex networks in recommendation systems[C]//Proc 2nd WSEAS Int Conf on Computer Engineering and Applications, World Scientific Advanced Series in Electrical and Computer Engineering, Acapulco, Mexico, 2008.
- [58] Balabanovic M, Shoham Y. Fab: content-based collaborative recommendation[J]. Communications of the ACM, 1997, 40(3): 66-72.
- [59] Basu C, Hirsh H, Cohen W. Recommendation as classification: using social and content-based information in recommendation[C]//Proc of the AAAI'98. Menlo Park: AAAI Press, 1998: 714-720.
- [60] Claypool M, Gokhale A, Miranda T, et al. Combining content-based and collaborative filters in an online newspaper[C]//Proc of the ACM SIGIR'99 Workshop Recommender Systems: Algorithms and Evaluation. New York: ACM Press, 1999.
- [61] Pazzani M. A framework for collaborative, content-based and demographic filtering[J]. Artificial Intelligence Review, 1999, 13(5): 393-408.
- [62] Tran T, Cohen R. Hybrid recommender systems for electronic commerce[C]//Proc Knowledge-Based Electronic Markets, Papers from the AAAI Workshop. Menlo Park: AAAI Press, 2000: 78-83.
- [63] Pazzani M, Billsus D. Learning and revising user profiles: The identification of interesting Web sites[J]. Machine Learning, 1997, 27: 313-331.
- [64] Park H S, Yoo J O, Cho S B. A context-aware music recommendation system using fuzzy Bayesian networks with utility theory[C]//Proceedings IEEE Fuzzy Systems and Knowledge Discovery, 2006, 4223: 970-979.
- [65] Good N, Schafer J B, Konstan J A, et al. Combining collaborative filtering with personal agents for better recommendations[C]//Proc Conf Am Assoc Artificial Intelligence, 1999: 439-446.
- [66] Melville P, Mooney R J, Nagarajan R. Content-boosted collaborative filtering for improved recommendations[C]//Proc 18th Nat'l Conf Artificial Intelligence, Edmonton, 2002: 187-192.
- [67] Cattuto C, Loreto V, Pietronero L. Semiotic dynamics and collaborative tagging[J]. PNAS, 2007, 104(5): 1461-1464.
- [68] Zhang Z, Lu L, Liu J G, et al. Empirical analysis on a keyword-based semantic system[J]. The European Physical Journal B, 2008, 66(4): 557-561.
- [69] Agrawal R, Imielinski T, Swami A. Mining association rules between set of items in large databases[C]//Proceedings of the

- ACM SIGMOD Conference on Management of Data, 1993: 207-216.
- [70] Han J, Pei J, Yin Y, et al. Mining frequent patterns without candidate generation[J]. Data Mining and Knowledge Discovery, 2004, 8: 53-87.
- [71] 李勇, 徐振宇, 张维明. Internet 个性化信息服务研究综述[J]. 计算机工程与应用, 2002, 38(19): 183-188.
- [72] 陈婷. 基于隐私保护的个性化推荐系统的研究与实现[D]. 上海: 复旦大学, 2008.
- [73] Mobasher B. WebPersonalizer: a server side recommender system based on Web usage mining, TR-01-004[R]. 1991.
- [74] 田晓珍, 尚冬娟. Web 的个性化服务[J]. 重庆工学院学报: 自然科学版, 2008, 22(7): 76-95.
- [75] Berkovsky S, Eytani Y, Kuflik T, et al. Privacy-enhanced collaborative filtering[C]//Workshop on Privacy-Enhanced Collaborative Filtering, Edinburgh UK, 2005.
- [76] Canny J. Collaborative filtering with privacy[C]//Proceedings of the Annual ACM Symposium on Applied Computing, Oa-Kland, 2002: 45-57.
- [77] Ramakrishnan N, Keller B J, Mirza B J, et al. Privacy risks in recommender systems[J]. IEEE Internet Computing, 2001, 11(2): 54-62.
- [78] Cassel L, Wolz U. Client side personalization[C]//DELOS Workshop Personalisation and Recommender Systems in Digital Libraries, Dublin, 2001.
- [79] Ceri S, Dolog P, Matera M, et al. Model-driven design of Web applications with client-side adaptation[C]//Web Engineering the 4th International Conference. Berlin: Springer Verlag, 2004: 201-214.
- [80] Mulligan D, Schwartz A. Your place or mine: privacy concerns and solutions for server and client-side storage of personal information[C]//Computers Freedom & Privacy Conference, 1999: 81-84.
- [81] Coroama V, Langheinrich M. Personalized vehicle insurance rates: a case for client-side personalization in ubiquitous computing[C]//Proceedings of PEP06, CHI 2006 Workshop on Privacy-Enhanced Personalization, Canada, 2006: 56-59.
- [82] Foner L. Yenta: a multi-agent referral-based matchmaking system[C]//International Conference on Autonomous Agents, Marina, 1997: 301-307.
- [83] Miller B N, Konstan J A, Riedl J. PocketLens: toward a personal recommender system[J]. ACM Transactions on Information Systems, 2004, 22: 437-476.
- [84] Berkovsky S, Eytani Y, Kuflik T, et al. Hierarchical neighborhood topology for privacy enhanced collaborative filtering[C]//Workshop on Privacy-Enhanced Personalization, Canada, 2006.
- [85] Lathia N, Hailes S, Capra L. Private distributed collaborative filtering using estimated concordance measures[J]. Recommendation Systems, 2007.
- [86] Xu Yabo, Zhang Benya, Wang Ke. Privacy-enhancing personalized Web search[C]//Proceedings of the 16th International Conference on World Wide Web, 2007.
- [87] Yao Y Y. Measuring retrieval effectiveness based on user preference of documents[J]. JASIS, 1995, 46: 133-145.
- [88] Heckerman D, Chickering D M, Meek C, et al. Dependency networks for inference, collaborative filtering, and data visualization[J]. J Mach Learn Res, 2000, 1: 49-75.
- [89] Swets J A. Information retrieval systems[J]. Science, 1963, 141: 245-250.
- [90] Swets J A. Effectiveness of information retrieval methods[J]. AmerDoc, 1969, 20: 72-89.
- [91] Kobsa A. Privacy-enhanced web personalization[C]//The Adaptive Web: Methods and Strategies of Web Personalization. New York: Springer-Verlag, 2007.
- [92] Kobsa A. Privacy-enhanced personalization[J]. The Communications of the ACM, 2007, 50(8): 24-33.
- [93] 余力, 董斯维, 郭斌. 电子商务推荐攻击研究[J]. 计算机科学, 2007, 34(5): 134-138.
- [94] 张富国, 徐升华. 推荐系统安全问题及技术研究综述[J]. 计算机应用研究, 2008, 25(3): 656-659.
- [95] Lam S K, Riedl J. Shilling recommender systems for fun and profit[C]//Proc of the 13th International Conference on World Wide Web. New York: ACM Press, 2004: 393-402.
- [96] Mobasher B, Burke R, Williams C, et al. Analysis and detection of segment-focused attacks against collaborative[C]//Recommendation: Proc of WebKDD Workshop. Berlin: [s.n.], 2006.
- [97] Wu X, Zhang Y D, Guo J B, et al. Web video recommendation and long tail discovering[C]//Proc of the 2008 IEEE Int'l Conf on Multimedia & Expo. Hoboken: Wiley-IEEE Press, 2008.
- [98] Zhang Y, Callan J, Minka T. Novelty and redundancy detection in adaptive filtering[C]//Proc of the 25th Annual Int'l ACM SIGIR Conf. New York: ACM Press, 2002: 81-88.
- [99] McDnald D W. Recommending collaboration with social networks: a comparative evaluation[C]//Proceedings of the 2003 ACM Conference on Human Factors in Computing Systems. Florida USA: Ft Lauderdale, 2003: 5-10.
- [100] Pennock D M, Horvitz E, Lee Giles C. Social choice theory and recommender systems: analysis of the axiomatic foundations of collaborative filtering[C]//Proceedings of the Seventeenth National Conference on Artificial Intelligence, 2000.
- [101] Lerman K. Social networks and social information filtering on digg[C]//Proc of the Int'l Conf on Weblogs and Social Media, 2006.
- [102] Ansari A, Essegiaier S, Kohli R. Internet recommendations systems[J]. Journal of Marketing Research, 2000, 37(3): 363-375.
- [103] Shani G, Brafman R, Heckerman D. An MDP-based recommender system[J]. The Journal of Machine Learning Research, 2005, 6: 1265-1295.